Konzeption einer serverlosen Computer-Vision-Pipeline auf AWS (Aufgabenstellung 2)

1. Problemabgrenzung, Zielsetzung & Budgetrahmen

Moderne Unternehmen stehen vor der Herausforderung, stetig wachsende Mengen unstrukturierter Bilddaten effizient, skalierbar und kostengünstig zu verarbeiten. Ziel dieses Projekts ist die Konzeption und Implementierung einer ereignisgesteuerten, vollautomatischen Computer-Vision-Pipeline in der Cloud. Sobald ein Bild hochgeladen wird, soll dieses automatisch analysiert, Text und Objekte erkannt und die extrahierten Metadaten in einer Datenbank strukturiert abgelegt werden. Sämtliche Komponenten nutzen ausschließlich das kostenlose Kontingent und im Leerlauf dürfen keine Fixkosten entstehen.

2. Auswahl und Begründung des Cloud-Anbieters & der Dienste

Als Cloud-Anbieter wird Amazon Web Services (AWS) gewählt. AWS bietet mit seinem ausgereiften Serverless-Ökosystem (*Function-as-a-Service / FaaS*) die beste Kombination aus hoher Entwicklungsgeschwindigkeit, nativer Ereignissteuerung und umfangreichen Free-Tier-Kontingenten. Der Betrieb virtueller Server wurde als nicht passend eingeschätzt, da durchgehend laufende Instanzen feste Fixkosten verursachen und manuelles Patch-Management erfordern. Ein PaaS-Ansatz bietet weniger Flexibilität bei der reinen Ereignisverarbeitung.

Als Architektur Komponenten wurde Amazon S3 als Objekt-Speicher gewählt, der Eingabe-Bucket empfängt Bilder und löst sofort ein s3:ObjectCreated-Ereignis aus. AWS Lambda als serverlose Python-Funktion verarbeitet das S3 Ereignis. Lambda skaliert bei eingehenden Ereignissen automatisch von Null auf hundert parallele Ausführungen und verursacht im Leerlauf keine Kosten. Für die Objekt- und Texterkennung wurde Amazon Rekognition gewählt, ein vollständig verwalteter KI-Dienst für Computer Vision. Lambda übergibt das Bild an Rekognition zur Inferenz. Amazon DynamoDB speichert die Analyseergebnisse als JSON-Dokumente mit geringer Latenz ab.

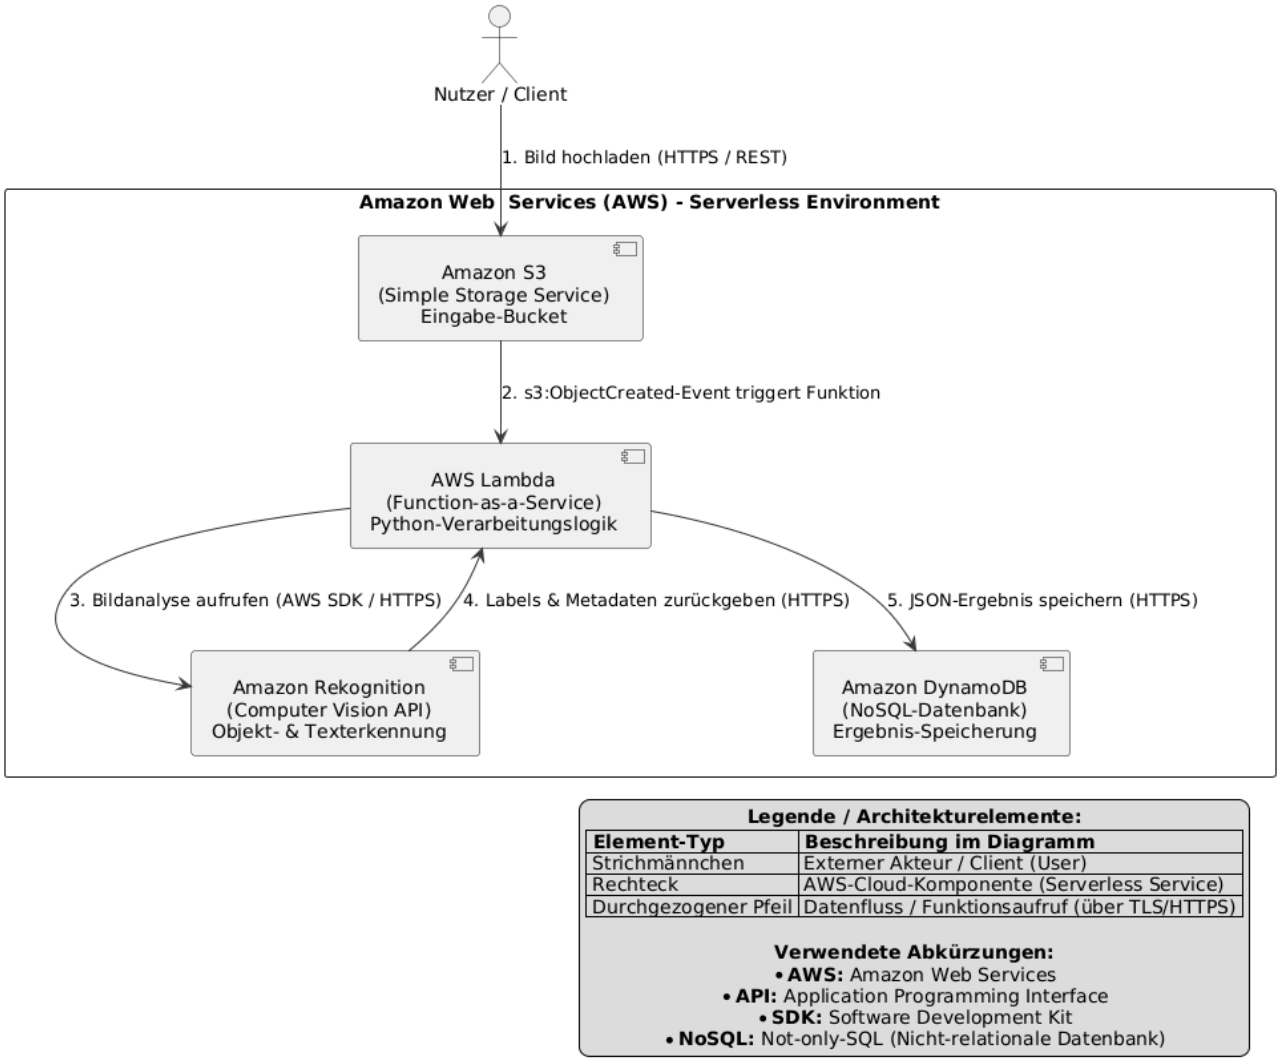
3. Sicherheits- & Verfügbarkeitskonzept

Die S3-Buckets sind privat konfiguriert, die Kommunikation zwischen den Diensten erfolgt nach dem Least-Privilege-Prinzip über dedizierte AWS IAM-Rollen. Daten werden sowohl im Ruhezustand in S3 und DynamoDB als auch während der Übertragung durch TLS/HTTPS verschlüsselt.

4. Methodik & Infrastructure as Code (IaC)

Zur Gewährleistung vollständiger Reproduzierbarkeit wird die gesamte Cloud-Infrastruktur deklarativ über das Open-Source-IaC-Tool Terraform definiert. Dies ermöglicht ein fehlerfreies, automatisiertes Deployment in Phase 2.

5. Serverless Computer Vision Pipeline UML-Diagramm



Legende / Architekturelemente:

Element-Typ	Beschreibung im Diagramm
Strichmännchen	Externer Akteur / Client (User)
Rechteck	AWS-Cloud-Komponente (Serverless Service)
Durchgezogener Pfeil	Datenfluss / Funktionsaufruf (über TLS/HTTPS)

Verwendete Abkürzungen:

- **AWS:** Amazon Web Services
- **API:** Application Programming Interface
- **SDK:** Software Development Kit
- **NoSQL:** Not-only-SQL (Nicht-relationale Datenbank)

Abb. 1 Serverless Computer Vision Pipeline